

Identyfikacja procesów przemysłowych		
Dominik Wróbel	06 XI 2018	Wt. 13:45, s. 111
Laboratorium 4		

1 Przebieg ćwiczenia

1.1. Zadanie 1

Zadanie polega na identyfikacji modelu ARMAX o strukturze

$$y_i = -a_1 y_{i-1} + b_0 u_{i-1} + e_i + c e_{i-1}$$

przy pomocy dwóch metod:

- Metody najmniejszych kwadratów
- Metody predykcji błędu

Identyfikacja dwiema metodami pozwoli na ich porównanie. W zadaniu wykonane zostanie również sprawdzenie czy reszty modelu zastosowanego dla metody najmniejszych kwadratów są białym szumem.

1.1.1. Metoda najmniejszych kwadratów

Zadanie rozpoczęto od zastosowanie metody najmniejszych kwadratów. W metodzie tej model reprezentowany jest równaniem:

$$y_i = -a_1 y_{i-1} + b_0 u_{i-1} + v_i$$

Współczynniki a_0 oraz b_0 wyznaczono korzystając z równania

$$\theta = (\Phi^T \cdot \Phi)^{-1} \cdot \Phi^T \cdot Y \quad (1)$$

gdzie

$$\Phi_{i1} = y_i, \quad i = 1, 2, \dots, n-1$$

$$\Phi_{j2} = u_j, \quad j = 1, 2, \dots, n-1$$

$$Y_k = y_k, \quad k = 2, 3, \dots, n$$


u oraz y to dane zmierzone podczas eksperymentu.

Z równania (4) otrzymano wartości parametrów:


$$\begin{bmatrix} a_1 \\ b_0 \end{bmatrix} = \begin{bmatrix} -0,9162 \\ 0,0582 \end{bmatrix} \quad (2)$$

Dane z eksperymentu oraz uzyskane z symulacji modelu przedstawia Rysunek 5. Różnice pomiędzy modelem a pomiarami przedstawia histogram 8.

Za pomocą testu Kołmogorowa - Smirnowa i testu Lillieforsa sprawdzono czy rozkład danych jest normalny. Pierwszy z nich dał wynik pozytywny, drugi negatywny. Na podstawie otrzymanego histogramu i wyników testów można uznać, że reszty modelu zastosowanego do metody najmniejszych kwadratów są szumem białym.



Rysunek 1: Porównanie modelu oraz danych z eksperymentu dla parametrów otrzymanych metodą najmniejszych kwadratów.



Rysunek 2: Histogram prezentujący różnice pomiędzy modelem a danymi z eksperymentu.

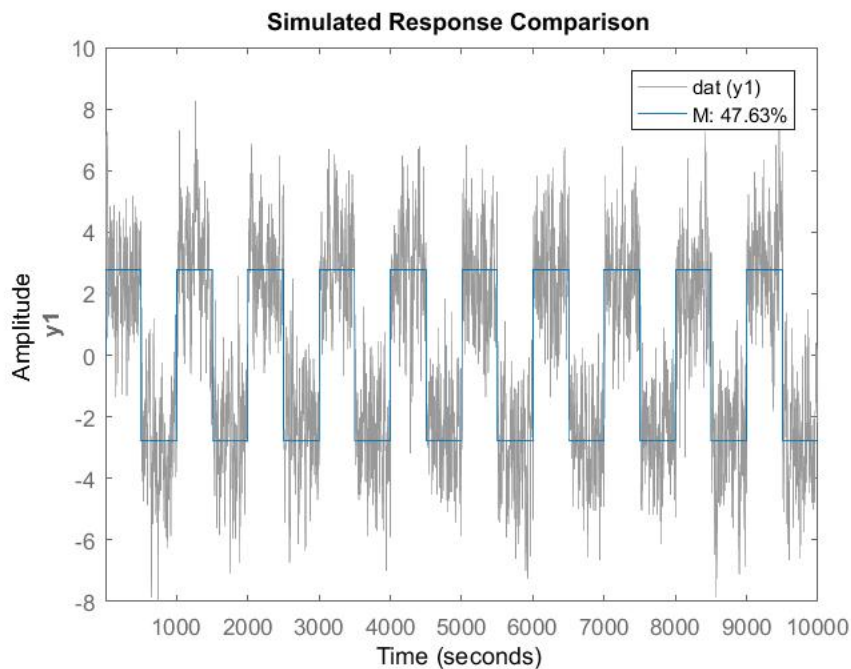
1.1.2. Metoda predykcji błędów i porównanie modeli

Metoda ta została zrealizowana w zadaniu numerycznie poprzez użyciu funkcji *armax* matlaba oraz wybór odpowiednich stopni wielomianu, dla modelu pierwszego rzędu stopnie te wynoszą 1.

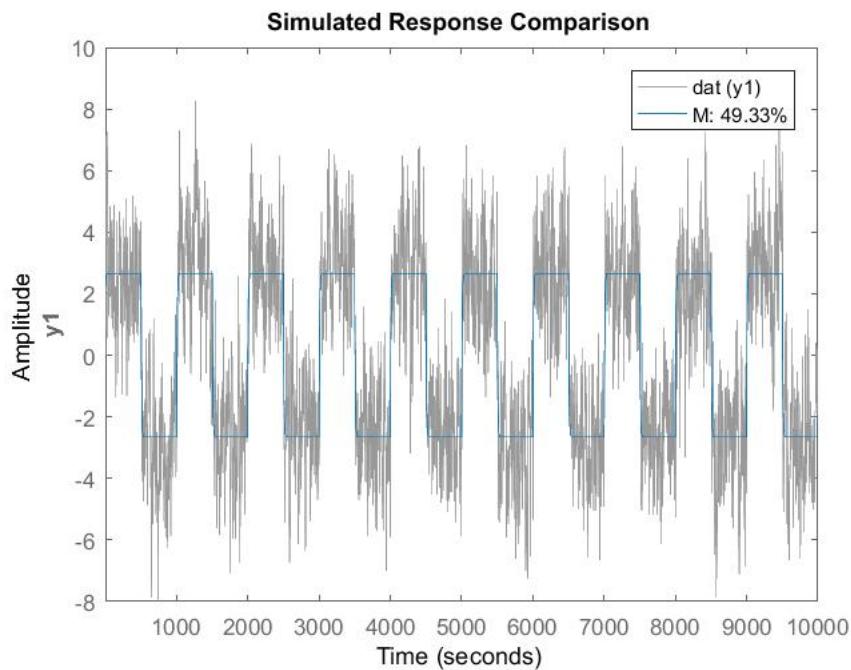
Otrzymano następujące wartości parametrów

$$\begin{bmatrix} a_1 \\ b_0 \end{bmatrix} = \begin{bmatrix} -0,8613 \\ 0,0923 \end{bmatrix} \quad (3)$$

Oceny jakości modeli dokonano przy użyciu funkcji matlaba *compare*. Funkcja ta oblicza estymator błędu modelu przy użyciu NRMSE (normalized root mean square). Funkcję tą zastosowano dla modelu otrzymanego z metody najmniejszych kwadratów oraz predykcji błędów. Wyniki prezentują Rysunki poniżej.



Rysunek 3: Metoda najmniejszych kwadratów



Rysunek 4: Metoda predykcji

Lepsze dopasowanie uzyskano dla metody predykcji, wynosi ono 49,33 % w porównaniu do metody najmniejszych kwadratów dla której wynosi 47,63 %.

1.1.3. Kod programu

Kod programu prezentuje listing poniżej.

```

1 clear all;
2 close all;
3
4 t = 1:1:10000;
5
6 load('data_01.mat');
7
8 phiMatrix(:,1) = y(1:end-1);
9 phiMatrix(:,2) = u(1:end-1);
10
11 Y = y(2:length(y));
12
13 params = ( phiMatrix' * phiMatrix ) \ phiMatrix' * Y;
14
15 figure()
16 plot(t,y);
17
18 yMod(1) = y(1);
19
20 for i = 2:length(y)
21     yMod(i) = params(1) * yMod(i-1) + params(2) * u(i-1);

```

```

22 end
23
24 hold on;
25 plot(t,yMod, 'r')
26
27 figure()
28 e = yMod' - y;
29 plot(t,e);
30
31 figure()
32 histfit(e);
33
34 kstestResult = kstest(e);
35 lillietestResult = lillietest(e);
36
37 T0 = 1;
38 dat = iddata(y,u,T0);
39 na = 1;
40 nb = 1;
41 nc = 1;
42 nk = 0;
43 M = armax(dat, [na nb nc nk]);
44 np = Inf;
45 figure()
46 [YH, FIT, X0] = compare(dat,M,np);
47 compare(dat,M,np);
48 figure()
49 compare(dat,tf(params(1),[params(2) 1]),np)

```

Listing 1: Zadanie 1

1.2. Zadanie 2

W zadaniu przyjęto metodykę analogiczną do tej wprowadzonej w zadaniu 1. Jedyną zmianą w tym przypadku jest model, którego rząd jest w tym zadaniu równy 2.

W zadaniu rozważany jest model ARMAX o strukturze:

$$y_i = -a_1 y_{i-1} - a_2 y_{i-2} + b_0 u_{i-1} + b_1 u_i - 2 + e_i + c_1 e_{i-1}$$

1.2.1. Metoda najmniejszych kwadratów

Dla metody najmniejszych kwadratów model ten reprezentuje równanie:

$$y_i = -a_1 y_{i-1} - a_2 y_{i-2} + b_0 u_{i-1} + b_1 u_{i-2} + v_i$$

Współczynniki a_0 oraz b_0 wyznaczono korzystając z równania

$$\theta = (\Phi^T \cdot \Phi)^{-1} \cdot \Phi^T \cdot Y \quad (4)$$

gdzie

$$\begin{aligned}\Phi_{i1} &= y_i, \quad i = 2, 3, \dots, n-1 \\ \Phi_{l2} &= y_l, \quad l = 1, 2, \dots, n-2 \\ \Phi_{m3} &= u_m, \quad m = 2, 3, \dots, n-1 \\ \Phi_{j4} &= u_j, \quad j = 1, 2, \dots, n-2 \\ Y_k &= y_k, \quad k = 3, 4, \dots, n\end{aligned}$$


u oraz y to dane zmierzone podczas eksperymentu.

Z równania (4) otrzymano wartości parametrów:


$$\begin{bmatrix} a_1 \\ a_2 \\ b_0 \\ b_1 \end{bmatrix} = \begin{bmatrix} -1,5523 \\ 0,9037 \\ 0,1823 \\ 0,1694 \end{bmatrix} \quad (5)$$

Dane z eksperymentu oraz uzyskane z symulacji modelu przedstawia Rysunek 5. Różnice pomiędzy modelem a pomiarami przedstawia histogram 8.

Za pomocą testu Kołmogorowa - Smirnowa i testu Lillieforsa sprawdzono czy rozkład danych jest normalny. Pierwszy z nich dał wynik pozytywny, drugi negatywny. Na podstawie otrzymanego histogramu i wyników testów można uznać, że reszty modelu zastosowanego do metody najmniejszych kwadratów są szumem białym.



Rysunek 5: Porównanie modelu oraz danych z eksperymentu dla parametrów otrzymanych metodą najmniejszych kwadratów.



Rysunek 6: Histogram prezentujący różnice pomiędzy modelem a danymi z eksperymentu.


1.2.2. Metoda predykcji błędów i porównanie modeli

Metoda ta została zrealizowana w zadaniu numerycznie poprzez użyciu funkcji *armax* matlaba oraz wybór odpowiednich stopni wielomianu, dla modelu pierwszego rzędu stopnie te wynoszą 1.


Otrzymano następujące wartości parametrów

$$\begin{bmatrix} a_1 \\ a_2 \\ b_0 \\ b_1 \end{bmatrix} = \begin{bmatrix} -1,5519 \\ 0,8873 \\ 0,0185 \\ 0,3158 \end{bmatrix} \quad (6)$$

Oceny jakości modeli dokonano przy użyciu funkcji matlaba *compare*. Funkcja ta oblicza estymator błędu modelu przy użyciu NRMSE (normalized root mean square). Funkcję tą zastosowano dla modelu otrzymanego z metody najmniejszych kwadratów oraz predykcji błędów. Wyniki prezentują Rysunki poniżej.



Rysunek 7: Metoda najmniejszych kwadratów



Rysunek 8: Metoda predykcji

Lepsze dopasowanie uzyskano ponownie dla metody predykcji, wynosi ono 77.85 % w porównaniu do metody najmniejszych kwadratów dla której wynosi 68,4 %.

1.2.3. Kod programu

Kod programu prezentuje listing poniżej.

```
1 clear all;
2 close all;
3
4 t = 1:1:10000;
5
6 load('data_02.mat');
7
8 phiMatrix(:,1) = y(2:end-1);
9 phiMatrix(:,2) = y(1:end-2);
10 phiMatrix(:,3) = u(2:end-1);
11 phiMatrix(:,4) = u(1:end-2);
12
13 Y = y(3:length(y));
14
15 params = ( phiMatrix' * phiMatrix ) \ phiMatrix' * Y;
16
17 figure()
18 plot(t,y);
19
20 yMod(1) = y(1);
21 yMod(2) = y(2);
22
23 for i = 3:length(y)
24     yMod(i) = params(1) * yMod(i-1) + params(2) *
25         yMod(i-2) + params(3) * u(i-1) + params(4) * u(i-2) ;
26 end
27
28 hold on;
29 plot(t,yMod, 'r')
30
31 figure()
32 e = yMod' - y;
33 plot(t,e);
34
35 figure()
36 histfit(e);
37
38 kstestResult = kstest(e);
39 lilietestResult = lilietest(e);
40
41 T0 = 1;
42 dat = iddata(y,u,T0);
43 na = 2;
44 nb = 2;
45 nc = 1;
46 nk = 0;
47 M = armax(dat, [na nb nc nk]);
48 np = Inf;
```

```
49 figure()
50 [YH, FIT, X0] = compare(dat,M,np);
51 compare(dat,M,np);
52 figure()
53 compare(dat,tf([ params(2) params(1) ],[params(4) params(3) 1]),np)
```

Listing 2: Zadanie 2

2 Wnioski końcowe

W obu przypadkach nieznacznie lepsza okazała się metoda predykcji. Metoda ta okazała się dokładniejsza w przypadku modelu większego rzędu. Obie metody różnią się pod względem działania, dla badanego zagadnienia warto zastosować obydwie w celu porównania otrzymanych podczas identyfikacji parametrów.